

## TPU-lite-SoC 模型结构描述

### I. 模型基础信息

模型类型：MLP； 推理模式：多 batch 推理，batch\_size = 16

### II. 数据定义

张量名称	维度	数据类型	说明
模型输入	(16, 256)	INT8	16 张图片*256 个像素输入
权重矩阵 1 (W1)	(256, 64)	INT8	第 1 层全连接层权重
权重矩阵 2 (W2)	(64, 32)	INT8	第 2 层全连接层权重
权重矩阵 3 (W3)	(32, 16)	INT8	第 3 层全连接层权重
偏置 1 (b1)	(1, 64)	INT32	第 1 层全连接层偏置
偏置 2 (b2)	(1, 32)	INT32	第 2 层全连接层偏置
偏置 3 (b3)	(1, 16)	INT32	第 3 层全连接层偏置
缩放因子 1 (scale1)	-	FP32	第 1 层输出量化缩放因子
缩放因子 2 (scale2)	-	FP32	第 2 层输出量化缩放因子
缩放因子 3 (scale3)	-	FP32	第 3 层输出量化缩放因子

### III. 多 batch 推理计算流程

#### # 第 1 层全连接计算

1. 矩阵乘法：输入矩阵  $\times$  W1  $\rightarrow$  矩阵 A (16, 64)，数据类型 INT32
2. 偏置相加：矩阵 A 逐行 + b1  $\rightarrow$  矩阵 B (16, 64)，数据类型 INT32
3. 量化缩放：矩阵 B 逐元素  $\times$  scale1  $\rightarrow$  矩阵 C (16, 64)，数据类型 INT8
4. 激活函数：矩阵 C 经过 ReLU 激活  $\rightarrow$  矩阵 D (16, 64)，数据类型 INT8

#### # 第 2 层全连接计算

5. 矩阵乘法：矩阵 D  $\times$  W2  $\rightarrow$  矩阵 E (16, 32)，数据类型 INT32
6. 偏置相加：矩阵 E 逐行 + b2  $\rightarrow$  矩阵 F (16, 32)，数据类型 INT32
7. 量化缩放：矩阵 F 逐元素  $\times$  scale2  $\rightarrow$  矩阵 G (16, 32)，数据类型 INT8
8. 激活函数：矩阵 G 经过 ReLU 激活  $\rightarrow$  矩阵 H (16, 32)，数据类型 INT8

#### # 第 3 层全连接计算

9. 矩阵乘法：矩阵 H  $\times$  W3  $\rightarrow$  矩阵 I (16, 16)，数据类型 INT32
10. 偏置相加：矩阵 I 逐行 + b3  $\rightarrow$  矩阵 J (16, 16)，数据类型 INT32
11. 量化缩放：矩阵 J 逐元素  $\times$  scale3  $\rightarrow$  矩阵 K (16, 16)，数据类型 INT8

### IV. 分类结果输出

1. 张量特征：矩阵 K[i] 的后 6 个元素恒为 0
2. 结果判定：矩阵 K[i] 前 10 个元素中最大值对应的索引即为数字 0-9 分类结果

## V. 第 1 层全连接计算流程细化

用  $\mathbf{A}$ ,  $\mathbf{W}$  表示一个矩阵，大小是  $16 \times 16$  个 INT8 数据，那么

输入矩阵可以被分块表示为:  $[\mathbf{A}_1, \mathbf{A}_2, \mathbf{A}_3, \dots, \mathbf{A}_{16}]$

权重矩阵可以被分块表示为:

$$\begin{bmatrix} W_{11}, & W_{12}, & W_{13}, & W_{14} \\ W_{21}, & W_{22}, & W_{23}, & W_{24} \\ \vdots & & & \vdots \\ W_{16,1}, & W_{16,2}, & W_{16,3}, & W_{16,4} \end{bmatrix}$$

下述是按模块划分的分步计算流程，绿色表示上一步中 VPU 得到/保存的数据

Systolic Array 计算得到  $A_1W_{11}$ ,  $A_1W_{12}$ ,  $A_1W_{13}$ ,  $A_1W_{14}$

VPU 存入数据

Systolic Array 计算得到  $A_2W_{21}$ ,  $A_2W_{22}$ ,  $A_2W_{23}$ ,  $A_2W_{24}$

VPU 计算得到  $A_1W_{11}+A_2W_{21}$ ,  $A_1W_{12}+A_2W_{22}$ ,  $A_1W_{13}+A_2W_{23}$ ,  $A_1W_{14}+A_2W_{24}$  并保存

Systolic Array 计算得到  $A_3W_{31}$ ,  $A_3W_{32}$ ,  $A_3W_{33}$ ,  $A_3W_{34}$

VPU 计算得到  $A_1W_{11}+A_2W_{21}+A_3W_{31}$ ,  $A_1W_{12}+A_2W_{22}+A_3W_{32}$ ,  $A_1W_{13}+A_2W_{23}+A_3W_{33}$ ,  $A_1W_{14}+A_2W_{24}+A_3W_{34}$  并保存

.....

Systolic Array 计算得到  $A_{16}W_{16,1}$ ,  $A_{16}W_{16,2}$ ,  $A_{16}W_{16,3}$ ,  $A_{16}W_{16,4}$

VPU 计算得到  $A_1W_{11}+ \dots +A_{16}W_{16,1}$ ,  $A_1W_{12}+ \dots +A_{16}W_{16,2}$ ,  $A_1W_{13}+ \dots +A_{16}W_{16,3}$ ,  $A_1W_{14}+ \dots +A_{16}W_{16,4}$  并保存

VPU 将数据视为  $16 \times 64$  个 INT32 的矩阵，每行与偏置 1 相加

VPU 将数据每个元素  $\times \text{scale1}$ ，处理到 INT8

VPU 将数据每个元素进行 ReLU

VPU 将数据 ( $16 \times 64$  个 INT8) 写回 Unified Buffer